

TPL 方法讲解

title: "TPL: 基于似然比的任务ID预测方法"

subtitle: "ICLR 2024 论文方法详解"

author: "Lin et al., 2024"

一、背景与问题设定

1.1 类增量学习 (CIL)

类增量学习 (Class Incremental Learning, CIL) 是持续学习中的核心难题：模型依次学习 T 个任务 $\{1, 2, \dots, T\}$ ，每个任务 t 拥有独立的类别集合 $\mathcal{Y}(t)$ ，且不同任务的类别**互不相交**：

$$\mathcal{Y}(i) \cap \mathcal{Y}(k) = \emptyset, \forall i \neq k$$

每个任务 t 的训练集为 $\mathcal{D}(t) = \{(x_j(t), y_j(t))\}_{j=1}^{n(t)}$ ，从联合分布 $P_{\mathcal{X}(t)\mathcal{Y}(t)}$ 中独立同分布采样。

CIL 的目标是学习一个函数：

$$f: \bigcup_{t=1}^T \mathcal{X}(t) \rightarrow \bigcup_{t=1}^T \mathcal{Y}(t)$$

关键挑战：测试时**不提供任务标识 (task-id)**，模型必须同时完成两件事：

- 预测样本属于哪个任务 (Task-ID Prediction, 简称 TP)
- 在该任务内预测正确类别 (Within-task Prediction, 简称 WP)

此外，一旦任务完成训练，其训练数据**不再可用**，导致**灾难性遗忘 (Catastrophic Forgetting, CF)** 问题。

二、核心分解公式

Kim et al. (2022b) 提出了 CIL 的理论分解框架，将最终分类概率分解为两个子概率的乘积：

$$P(y_j(t)|x) = P(y_j(t)|x, t) \times P(t|x)$$

任务内预测 (WP) × 任务ID预测 (TP)

其中：

- $P(y_j(t)|x, t)$ ：WP 概率——已知样本属于任务 t 时，预测其类别为 $y_j(t)$ 的概率。由任务专属分类头的 softmax 输出给出，通常十分准确。
- $P(t|x)$ ：TP 概率——样本 x 属于任务 t 的概率。这是 CIL 的**核心难点**，也是 TPL 的主要贡献所在。

最终预测类别为：

$$\hat{y} = \operatorname{argmax}_t, j P(y_j(t)|x, t) \times P(t|x)$$

三、训练阶段：引入「O类」

3.1 网络结构

TPL 使用预训练的 DeiT-S/16 Transformer 作为骨干网络（参数固定），在每个 Transformer 层插入可训练的 Adapter 模块，通过 HAT（Hard Attention to the Task）学习任务专属的稀疏 mask，防止灾难性遗忘。

每个任务 t 的模型由两部分组成：

- 特征提取器 $h(x; \phi(t))$ ：提取样本 x 在任务 t 的 mask 下的特征表示
- 任务专属分类头 $f(z; \theta(t))$ ：在特征空间上做分类

3.2 O 类设计

与传统分类器不同，TPL 为每个任务 t 额外添加一个「O类」（Others），代表来自其他所有先前任务的回放数据 $\text{Buf}_{<t}$ 。这使模型能够感知「不属于本任务」的数据分布，为后续的似然比计算奠定基础。

3.3 训练损失

学习任务 t 时，模型接收当前任务数据 $\mathcal{D}(t)$ 和回放数据 $\text{Buf}_{<t}$ （标记为 O 类），最小化以下损失：

$$\mathcal{L}(\theta(t), \phi(t)) = \mathbb{E}(x, y) \sim \mathcal{D}(t) \cup \text{Buf}_{<t} [\mathcal{L}_{\text{CE}}(f(h(x; \phi(t)); \theta(t)), y)] + \mathcal{L}_{\text{HAT}}$$

其中：

- $\mathcal{L}_{\text{CE}}$ ：多分类交叉熵损失（含 O 类）
- $\mathcal{L}_{\text{HAT}}$ ：HAT 正则化项，通过累积 mask 阻断旧任务关键神经元的梯度更新，防止遗忘

注意：O 类仅在训练时使用，推理时不参与 softmax 计算。

四、理论核心：似然比检验

4.1 问题形式化

TPL 将 Task-ID 预测问题形式化为二元假设检验：

$$H_0: x \sim P_t \text{ vs } H_1: x \sim P_{tc}$$

其中：

- P_t ：任务 t 的数据分布
- $\mathcal{U}_{\text{CIL}} = \{1, 2, \dots, T\}$ ：所有已学任务的集合
- $tc = \mathcal{U}_{\text{CIL}} \setminus \{t\}$ ： t 的补集，即「除任务 t 之外的所有任务」
- P_{tc} ：其他所有任务数据的混合分布

4.2 两个核心定理

定理 4.1 (UMP 检验)：基于 Neyman-Pearson 引理，以下拒绝域对应**唯一的一致最强检验 (UMP)**：

$$\mathcal{R} := \{x: \text{pt}(x)/\text{ptc}(x) < \lambda_0\}$$

其中 λ_0 为指定显著水平下的阈值， $\text{pt}(\cdot)$ 和 $\text{ptc}(\cdot)$ 分别为 P_t 和 P_{t^c} 的概率密度函数。

定理 4.2 (最大化 AUC)：上述 UMP 检验同时**最大化** P_t 与 P_{t^c} 之间二分类的 ROC-AUC。

两个定理共同说明：**似然比 $\text{pt}(x)/\text{ptc}(x)$ 是 Task-ID 预测的理论最优分数。**

4.3 为何 CIL 中可行？

在传统 OOD 检测中，外部分布 P_{t^c} 对应「世界上所有其他类别」——集合无穷大，无法估计。

CIL 的关键优势： P_{t^c} 是其他**有限个已学任务**的混合分布，可通过回放缓冲区中保存的样本来近似估计：

$$P_{t^c} \approx 1/T - 1 \sum_{t^* \neq t} P_{X(t^*)} \quad (\text{每个任务等权混合})$$

这是 TPL 相比传统 OOD 方法的**根本性突破**。

五、似然比分数的实践计算

5.1 基于能量模型 (EBM) 的参数化

由于在高维原始图像空间直接估计密度函数困难，TPL 在**低维特征空间**中进行估计。利用能量模型将密度参数化：

$$\text{pt}(x) = \exp\{\text{Et}(x)\} Z_1, \text{ptc}(x) = \exp\{\text{Etc}(x)\} Z_2$$

其中 Z_1, Z_2 为归一化常数， $\text{Et}(\cdot)$ 、 $\text{Etc}(\cdot)$ 为能量函数（与概率密度正相关）。

对数似然比为：

$$\text{SLR}(t)(x) = \log \text{pt}(x) / \text{ptc}(x) = \text{Et}(x) - \text{Etc}(x) + \log Z_2 Z_1 \text{__常数, 忽略}$$

$$\text{SLR}(t)(x) := \text{Et}(x) - \text{Etc}(x)$$

5.2 具体估计方法

能量项	估计方法	原理
$\text{Et}(x)$ (任务内密度)	Mahalanobis Distance (MD)	假设类条件分布为高斯混合，用各类中心和协方差估计
$-\text{Etc}(x)$ (任务外密度)	KNN 距离 $d_{\text{KNN}}(x, \text{Buftc})$	非参数估计，k 近邻距离小 $\rightarrow$ x 靠近其他任务分布

MD 分数定义为特征到所有类中心的最小马氏距离的负值（值越大表示越接近任务 t 的分布）：

$$\text{SMD}(t)(x) = -\min_{c \in \mathcal{Y}(t)} (h(x; \phi(t)) - \mu_c)^\top \Sigma^{-1} (h(x; \phi(t)) - \mu_c)$$

KNN 距离为特征与其他任务回放数据的 k 近邻距离：

$$\text{dKNN}(x, \text{Buftc}) = k\text{-th nearest distance of } h(x; \phi(t)) \text{ to features of Buftc}$$

最终 LR 分数：

$$\text{SLR}(t)(x) = \alpha \cdot \text{SMD}(t)(x) + \text{dKNN}(x, \text{Buftc})$$

其中 α 为平衡两项量纲的超参数。

六、融合 Logit-based 分数

6.1 能量组合框架

TPL 进一步将特征空间的 LR 分数与 logit 空间的分数融合，利用 Du et al. (2020) 提出的**能量模型 OR 门组合**：

$$\text{Ecomp}(x) = \log(\exp\{\alpha_1 \cdot \text{Slogit}(t)(x)\} + \exp\{\alpha_2 \cdot \text{SLR}(t)(x)\})$$

6.2 选择 MLS 作为 Logit-based 分数

TPL 选用**最大 Logit 分数** (Maximum Logit Score, MLS)：

$$\text{SMLS}(t)(x) = \max_{j \in \mathcal{Y}(t)} f_j(h(x; \phi(t)); \theta(t))$$

6.3 最终 TPL 分数

合并 α 系数后，最终的 TPL 分数为：

$$\text{STPL}(t)(x) = \log(\exp\{\beta_1 \cdot \text{SMLS}(t)(x)\} + \exp\{\beta_2 \cdot (\text{SMD}(t)(x) + \text{dKNN}(x, \text{Buftc}))\})$$

缩放系数由**训练集经验均值的倒数**确定，保证两项具有可比的量纲：

$$1/\beta_1 = 1/|\mathcal{D}(t)| \sum_{x \in \mathcal{D}(t)} \text{SMLS}(t)(x), 1/\beta_2 = 1/|\mathcal{D}(t)| \sum_{x \in \mathcal{D}(t)} \text{SMD}(t)(x)$$

由于 dKNN 的量纲已接近 1，因此不再单独归一化。

七、输出 Task-ID 概率

TPL 分数 $\text{STPL}(t)(x)$ 仍是未归一化的能量值，通过**低温 softmax** 转化为概率：

$$P(t|x) = \text{softmax}[\text{STPL}(1)(x)\gamma, \text{STPL}(2)(x)\gamma, \dots, \text{STPL}(T)(x)\gamma]_t$$

其中温度参数 $\gamma = 0.05$ (低温)，使概率分布更集中，鼓励模型做出置信的 task-id 预测。

将 TP 和 WP 代入分解公式，得到最终的 CIL 预测：

$$\hat{y} = \arg\max_{t,j} [\text{softmax}(f(h(x; \phi(t)); \theta(t)))_j] \text{ WP: } P(y_j(t)|x, t) \times P(t|x) \text{ TP}$$

八、完整推理流程

对于测试样本 x ，推理过程如下：

Step 1: 对所有 T 个任务并行计算 TPL 分数（每次使用对应任务的 mask 和分类头）：

$$STPL(t)(x)=\log(\exp\{\beta_1\cdot SMLS(t)\}+\exp\{\beta_2\cdot (SMD(t)+dKNNtc)\}),t=1,...,T$$

Step 2: 低温 softmax 归一化，得到 task-id 概率分布 $\{P(t|x)\}_{t=1}^T$

Step 3: 对每个任务 t ，用其专属分类头计算 WP 概率 $P(y_j(t)|x,t)$ （不含 O 类）

Step 4: 最终预测 $\hat{y}=\operatorname{argmax}_{t,j}P(y_j(t)|x,t)\times P(t|x)$

九、方法总结

模块	技术选择	作用
防遗忘	HAT mask（参数隔离）	阻断旧任务关键神经元的梯度，消除 CF
骨干网络	预训练 DeiT-S/16 + Adapter	高质量特征，参数高效适配
训练目标	含 O 类的多分类交叉熵	使模型感知「其他任务」的分布
任务内密度 P_t	Mahalanobis Distance（MD）	测试时无需原始训练数据
任务外密度 P_{tc}	KNN + 回放缓冲区 Buftc	非参数估计，利用 CIL 中可获取的 P_{tc} 信息
分数融合	EBM OR 门（LR + MLS）	结合特征空间和 logit 空间的互补信息
概率归一化	低温 softmax（ $\gamma=0.05$ ）	置信的 task-id 预测分布

TPL 的根本创新在于：在 CIL 场景下， P_{tc} **可以被估计**——这一点传统 OOD 检测无法做到。由此将 task-id 预测从启发式 OOD 检测升级为有 Neyman-Pearson 理论保障的最优似然比检验。